

实验二

要求：利用给定的中英文文本序列（见 Chinese.txt 和 English.txt），分别利用以下给定的中英文分词工具进行分词并对不同分词工具产生的结果进行简要**对比分析**，将实验过程与结果写成实验报告，实验课结束后提交。

中文分词工具

Jieba（重点），尝试三种分词模式与自定义词典功能：

<https://github.com/fxsjy/jieba>

SnowNLP：

<https://github.com/isnowfy/snownlp>

THULAC：

<https://github.com/thunlp/THULAC-Python>

NLPIR：

<https://github.com/tsroten/pynlpir>

https://blog.csdn.net/weixin_34613450/article/details/78695166

StanfordCoreNLP：

<https://github.com/Lynten/stanford-corenlp>

HanLP（选做，需要额外安装 Microsoft Visual C++ 14.0）

<https://github.com/hankcs/pyhanlp>

英文分词工具

NLTK：

<http://www.nltk.org/index.html>

<https://github.com/nltk/nltk>

<https://www.jianshu.com/p/9d232e4a3c28>

SpaCy：

<https://blog.csdn.net/u012436149/article/details/79321112>

<https://spacy.io/usage/linguistic-features#section-tokenization>

StanfordCoreNLP：

<https://github.com/Lynten/stanford-corenlp>